

Lab 02

Bài 1: Unigram

1, Vocabulary: { the, cat, eats, fish, likes, dog, meat } $\Rightarrow V = 7$

2, Tổng số token $N = 12$

$$3, \quad P(w) = \frac{c(w)}{N}$$

$$P(\text{the}) = \frac{3}{12} = 0.25$$

$$P(\text{cat}) = \frac{2}{12} \approx 0.1667$$

$$P(\text{fish}) = \frac{2}{12} \approx 0.1667$$

$$P(\text{dog}) = \frac{1}{12} \approx 0.0833$$

$$4, \quad P(\text{eats}) = \frac{2}{12} \approx 0.1667$$

$$P(\text{likes}) = \frac{1}{12} \approx 0.0833$$

$$P(\text{meat}) = \frac{1}{12} \approx 0.0833$$

$$\Rightarrow \sum_w P(w) = 0.25 + 0.1667 + 0.1667 + 0.0833 + 0.1667 + 0.0833 + 0.0833 = 1$$

Bài 2: Bigram

$$P(\text{cat} | \text{the}) = \frac{c(\text{the cat})}{c(\text{the})} = \frac{2}{3} \approx 0.6667$$

$$c(\text{the}) = 3$$

$$c(\text{the cat}) = 2$$

Question: Tại sao tổng xác suất của các từ đứng sau the phải bằng 1 nếu vocabulary và context được xử lý đầy đủ?
Answer:

Với một context h cố định

$$\sum_{w \in V} P(w|h) = \sum_{w \in V} \frac{c(h,w)}{c(h)} = \frac{\sum_w c(h,w)}{c(h)} = \frac{c(h)}{c(h)} = 1$$

Miền là vocabulary chứa đầy đủ mọi từ có thể đứng sau h, và 0 bỏ sót token kết thúc câu. Trong corpus này, sau "the" chỉ có:

cat : 2

dog : 1

Nên

$$P(\text{cat}|\text{the}) = \frac{2}{3}, \quad P(\text{dog}|\text{the}) = \frac{1}{3}$$

$$\Rightarrow \text{Tổng} = 1.$$

Bài 3: - Xác suất câu

Bigram:

$$P(S) = P(\text{the}) P(\text{cat}|\text{the}) P(\text{eats}|\text{cat}) P(\text{fish}|\text{eats})$$

$$P(\text{the}) = 1/4; \quad P(\text{cat}|\text{the}) = 2/3$$

$$P(\text{eats}|\text{cat}) = \frac{c(\text{cat eats})}{c(\text{cat})} = \frac{1}{2}$$

$$P(\text{fish}|\text{eats}) = \frac{c(\text{eats fish})}{c(\text{eats})} = \frac{1}{2}$$

$$\Rightarrow P(S) = \frac{1}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{24} \approx 0.04167$$

Log probability:

$$\log P(S) = \log(1/24) \approx -3.178$$

② Nếu thêm một từ vào câu, xác suất của câu có tăng lên 0?

$\Rightarrow$ Không, vì mỗi xác suất thành phần đều ≤ 1 , nên

$$P(S_{\text{new}}) = P(S) \cdot P(S_{\text{new}}|\text{context}) \leq P(S)$$

Thêm từ chỉ có thể làm xs giảm or giữ nguyên. Do đó thay duy $P(s)$ tho để so sánh các câu dài ngắn khác nhau. Cần duy log-probability chuẩn hoá hoặc per plurality.

Bài 4: Sentence ranking

Cho :

$s_1 = \text{the cat eats fish}$

$s_2 = \text{the dog eats fish}$

Dữ liệu:

s_1 có thể cao hơn vì "the cat" xuất hiện 2 lần, còn "the dog" xuất hiện 1 lần.

Thước đo:

s_1 :

$$P(s_1) = P(\text{the}) P(\text{cat} | \text{the}) P(\text{eats} | \text{cat}) P(\text{fish} | \text{eats}) \\ = \frac{1}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{24}$$

s_2 :

$$P(s_2) = P(\text{the}) P(\text{dog} | \text{the}) P(\text{eats} | \text{dog}) P(\text{fish} | \text{eats}) \\ = \frac{1}{4} \cdot \frac{1}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{24}$$

Vậy 2 câu ~~hòa~~ = nhau theo bigram MLE

⇒ Điều này cho thấy trước giờ "cat phá" biến hơn "chưa đủ", xác suất phụ thuộc toàn bộ chuỗi bigram.

2. Zero Probability - Section 8, 9.

Corpus : I like NLP I like AI I study NLP

Token : I | like | NLP | I | like | AI | I | study | NLP

$$P(\text{AI} | \text{study}) = \frac{C(\text{study AI})}{C(\text{study})} = \frac{0}{1} = 0$$

② Điều gì xảy ra khi tính xs câu chứa bigram này?

VD : "I like AI"

$$P(s) = P(I) P(\text{study} | I) P(\text{AI} | \text{study})$$

Vì $P(AI | \text{study}) = 0$, nên

$$P(s) = 0.$$

① Mô hình có biết câu đó chắc chắn 0 hay xảy ra 0?
 $\Rightarrow$ Không. Đây chỉ là zero-frequency problem: mô hình chưa quan sát thấy bigram "study AI" trong training corpus.

Ko quan sát thấy khái xác suất thực sự $= 0$.

3.

Smoothing - Section 10, 11

Công thức Laplace / Add-one

$$P_L(w|h) = \frac{C(h,w) + 1}{C(h) + V}$$

Bảng:

$$C(\text{cat}) = 10, C(\text{eat eats}) = 0, V = 5$$

Khi $C(\text{cat eats}) = 0$:

$$P_L(\text{eats} | \text{cat}) = \frac{0 + 1}{10 + 5} = \frac{1}{15} \approx 0.0667$$

Khi $C(\text{cat eats}) = 3$

$$P_L(\text{eats} | \text{cat}) = \frac{3 + 1}{10 + 5} = \frac{4}{15} \approx 0.2667$$

Smoothing đã thay đổi xs của các bigram như?

- Mỗi số $C(h)$ lên $C(h) + V$, nên mọi xs của bigram đã quan sát đều bị giảm

- Các bigram chưa quan sát được gần như xs bằng nhỏ $\frac{1}{C(h) + V}$

- Tổng phân phối trên toàn vocabulary vẫn ≥ 1

$$\sum_w \frac{C(h,w) + 1}{C(h) + V} = \frac{C(h) + V}{C(h) + V} \geq 1$$