HAI TIEN

Lab_04 – Prediction

Dataset: IMDb (50000 review, sentimen Positive / negative)
cân bằng 25k/25k

6. Prediction giữa hai Representation (dataset IMDb)

- Precision: TF-IDF phù hợp hơn Average Word2Vect cho IMDb

- Reason: sentiment ở IMDb thường quyết định bởi từ cụ thể (great, awful, boring, waste). TF-IDF + Logistic Regression giữ trọng số riêng cho từng từ/cụm từ (có thể thêm bigram như "not good". Average Word2Vec trung bình các vector nên mất thông tin từng từ, nếu có thể tự và phủ định; ngoài ra Word2Vec học theo ngữ cảnh nên "good" và "bad" có vecto gần nhau (cùng context) và K° tách sentiment rõ.
- Confidence: trung bình

10. Prediction trước experiment

Prediction 1
Pred: Có, tốt, kỳ vọng acc cao khoảng 88–90%.
Reason: review dài, nhiều từ mang sentiment rõ, dữ liệu 50k đủ lớn để học trọng số từ, Logistic Regression cân bằng trên feature sparse nhiều chiều
Confidence: Cao

Prediction 2.
Pred: K không. Dự đoán Average Word2Vec đạt khoảng 82–86% thấp hơn TF-IDF
Reason: dense embedding giúp khái quát nghĩa gần nhau, nhưng bị trung bình hoá làm mất tín hiệu từ cụ thể, phủ định và thứ tự Word2Vec không được huấn luyện cho sentiment.
Confidence: trung bình – cao

Prediction 3:

Pred: Không. Có thể tăng lúc đầu rồi bão hòa, hoặc tăng không đáng kể

Reason: Từ hiếm thêm vào ít xuất hiện nên trọng số khó học, thêm nhiều vì ngẫu có overfit; phần lớn thông tin sentiment nằm ở các từ phổ biến.

Confidence: Cao

Prediction 4:

Pred: Không, Có thể = đôi hoặc giảm nhẹ.

Reason: ~~Từ hiếm~~ Danh sách stopword thường chứa các từ phủ định (not, no, nor, don't) rất quan trọng cho sentiment ("not good"). Với TF-IDF thì từ phổ biến đã bị IDF giảm trọng số sẵn

Confidence: Trung bình.

Prediction 5

- Pred: Có thể, vì với IMDb (dataset cân bằng) thì 2 metric gần như trùng nhau; khác biệt rõ khi dữ liệu imbalance.
- Reason: acc cao bị chi phối bởi lớp đa số; F_1 xét precision và recall của từng lớp. Khi các lớp cân bằng thì hai metric cho cùng thứ tự giữa các model.
- Confidence: Cao