Lab_06 - Calculations

6. Softmax attention weights (ví dụ)

$s = [2, 1, 0] \rightarrow e^2 = 7.389, e^1 = 2.718, e^0 = 1$

$\Rightarrow$ Tổng = 11.107

$\alpha = [\frac{7.389}{11.107}, \frac{2.718}{11.107}, \frac{1}{11.107}] = [0.665, 0.243, 0.090]$

-> Token 1 (score lớn nhất) nhận attention lớn nhất

5. Bài tập tính toán

Bài 1: - Attention scores

$q = [1, 2]^T, k_1 = [1, 0], K_2 = [0, 1], k_3 = [1, 1]$

i	$S_i = q^T k_i$	Result
1	$1 \times 1 + 2 \times 0$	1
2	$1 \times 0 + 2 \times 1$	2
3	$1 \times 1 + 2 \times 1$	3

Score vector s = Result = $[1, 2, 3]$

9. Bài 2: - Softmax

$s = [1, 2, 3] \rightarrow e^1 = 2.718, e^2 = 7.389, e^3 = 20.086$

Tổng = 30.193

$\alpha = [0.090, 0.245, 0.665]$; ktra: $0.090 + 0.245 + 0.665 = 1$

Vì exp là hàm tăng biến và mọi x_i chia cùng một mẫu số nên score lớn hơn -> exp lớn hơn -> weight lớn hơn, exp còn khuếch đại khoảng cách; chênh 1 đơn vị score thành gấp $e = 2.7$ lần weight.

10. Bài 3 - Context vector

$x = [0.1, 0.2, 0.7], v_1 = [1, 0], v_2 = [0, 1], v_3 = [2, 2]$

HAI TIEN

$c = 0.1 \times [1,0] + 0.2 \times [0,1] + 0.7 \times [2,2]$

$= [1.5, 1.6]$

=> v_3 đóng góp nhiều nhất : weight lớn nhất 0.7 và cũng là vecto lớn nhất $[1.4, 1.4]$ trong tổng $[1.5, 1.6]$

11. Bài 4 - Toàn bộ attention computation

$q = [1,0]$; $k_1 = [1,0]$, $k_2 = [0,1]$, $k_3 = [1,1]$

$v_1 = [1,0]$, $v_2 = [0,2]$, $v_3 = [2,1]$

Bước	Phép tính
1. Scores	$s = [q^T k_1, q^T k_2, q^T k_3] = [1,0,1]$
2. Softmax	$[e,1,e]/(2e+1) = [2.718, 1, 2.718]/6.437$
3. Weighted Sum	$0.422 \times [1,0] + 0.155 \times [0,2] + 0.422 \times [2,1]$
	$= [0.422, 0] + [0, 0.311] + [0.845, 0.422]$

~~K~~q	kq^2
1	$[1,0,1]$
2	$\alpha = [0.422, 0.155, 0.422]$
3	$c = [1.267, 0.733]$

k_1 và k_3 cùng score nên nhận weight bằng nhau; k_2 vuông góc với q nên weight nhỏ nhất.

14. Bài tập - Scaling

$d_k = 4 \Rightarrow \sqrt{d_k} = 2$; $Qk^T = [4,2,0]$

	Score	Softmax	Max weight
Không Scaling	$[4,2,0]$	$[0.867, 0.117, 0.016]$	0.867
Có Scaling (/2)	$[2,1,0]$	$[0.665, 0.245, 0.090]$	0.665

Scaling thu nhỏ khoảng cách giữa các score, nên softmax phẳng hơn. Không scaling, khi d_k lớn hơn thì dot product lớn, softmax gần one-hot và gradient gần 0.

NHIỆT ĐỘ

16. Temperature

Given vector $s = [2, 1, 0]$, tính softmax($\cdot/T$)

Entropy $H = -\sum p_i \ln p_i$ (tối đa $\ln 3 = 1.099$)

Temperature	s/T	weights	Max weight
0.5	[4, 2, 0]	[0.867, 0.117, 0.016]	0.867
1.0	[2, 1, 0]	[0.665, 0.245, 0.090]	0.665
2.0	[1, 0.5, 0]	[0.506, 0.307, 0.186]	0.506

Entropy	Nxet
0.441	Tập trung nhất
0.832	T bình
1.020	Phẳng nhất

→ T thấp: distribution tập trung; T cao: distribution phẳng. Thứ tự các weight không đổi.

17. Numerical Stability

$x = [1000, 1001, 1002]$: e^{1000} bị tràn số (inf), nên $\frac{inf}{inf} =$ NaN

Trừ $\max(x) = 1002$: $x - \max = [-2, -1, 0]$ → softmax = [0.090, 0.245, 0.665]

Trừ max không đổi kết quả vì $\frac{e^{(x_i - u)}}{\sum_j e^{(x_j - m)}} = \frac{(e^{x_i} \times e^{(-m)})}{e^{-m} \cdot \sum_j e^{x_j}}$

Hằng số e^{-m} ở tử và mẫu triệt tiêu. Sau khi trừ, số mũ lớn nhất là 0 nên không tràn số.

21. Bài tập self-attention

Tự chọn $d = d_k = 2$ $\sqrt{d_k} = 1.414$

X (hàng = I, like, cat) = [[1, 0], [0, 1], [1, 1]]

HAI TIEN

Bước 1: Q, K, V

Token	Q = X.W_Q	K = X.W_K	V = X.W_V
I	[1,0]	[1,1]	[1,0]
like	[1,1]	[0,1]	[0,2]
cats	[2,1]	[1,2]	[1,2]

Bước 2: QK^T (hàng = query, cột = key I / like / cats)

	I	like	cats
I	1	0	1
like	2	1	3
cats	3	1	4

Bước 3: Chia $\sqrt{d_k}$, softmax theo hàng (A, mỗi hàng tổng = 1)

	Scaled scores	A: I	like	cats
I	[0.707, 0, 0.707]	0.401	0.198	0.401
like	[1.414, 0.707, 2.121]	0.284	0.140	0.576
cats	[2.121, 0.707, 2.828]	0.306	0.074	0.620

Bước 4: Output = AV

Token	Phép tính	Output
I	0.401.[1,0] + 0.198.[0,2] + 0.401 [1,2]	[0.802, 1.198]
like	0.284[1,0] + 0.140.[0,2] + 0.576 [1,2]	[0.860, 1.432]
cats	0.306[1,0] + 0.074.[0,2] + 0.620 [1,2]	[0.926, 1.389]

→ Output của mỗi token là tổ hợp value của cả ba token:
"like" lấy 57.6% thông tin từ "cats". Một token tương tác tương tự với mọi token khác trong cùng sequence

25. Experiment 5/29 - Kích thước matrix (TxT)

T	Attention matrix	Số phú
10	10×10	100
100	100×100	10000
500	500×500	250000
1000	1000×1000	1 000 000
10000	10000×10000	1 000 000 00

=> $O(T^2)$, cả bộ nhớ lẫn phép tính

Với T = 10000 dạng float32 : $10^8 \times 4$ byte = 400MB

cho một attention matrix (một head, một câu)

Lab - 06 - Prediction

1. Prediction trc experiment

Prediction 1 - key đó có độ product lớn hơn các key khác thì attention weight thế nào?

- Prediction : weight của key đó lớn nhất
- Reason : softmax đồng biến, score lớn hơn → exp lớn hơn chênh score càng nhiều thì weight càng dồn về key đó.
- Confidence : Cao

Prediction 2 - Scores bằng nhau s = [1,1,1,1] thì attention weight thế nào?

- Prediction : phân phối đều, mỗi weight = 1/4 = 0,25
- Reason : các e bằng nhau nên mỗi phần tử = 1/T ; softmax chỉ phụ thuộc chênh lệch giữa các score, k° phụ thuộc gtri tuyệt đối. Context vecto khi đó = trung bình các value.
- Confidence : Cao