T	Attention matrix	Số phú
10	10x10	100
100	100x100	10000
500	500 x 500	250000
1000	1000 x 1000	1 000 000
10000	10 000 x 10 000	1 000 000 00

=> $O(T^2)$, cả bộ nhớ lẫn phép tính

Với T = 10000 thì dạy float 32 : $10^8 \times 4$ byte = 400MB

cho một attention matrix (một head, một câu)

Lab - 06 - Prediction

1. Prediction trc experiment

Prediction 1 - key đó có độ product lớn hơn các key khác thì attention weight thế nào?

- Prediction : weight của key đó lớn nhất
- Reason : softmax đồng biến, score lớn hơn -> exp lớn hơn chênh score càng nhiều thì weight càng dồn về key đó.
- Confidence : Cao

Prediction 2 :- Scores bằng nhau s = [1,1,1,1] thì attention weight thế nào?

- Prediction : phân phối đều, mỗi weight = 1/4 = 0,25
- Reason : các e bằng nhau nên mỗi phần = 1/4 ; softmax chỉ phụ thuộc chênh lệch giữa các score, k° phụ thuộc gtri tuyệt đối. Context vecto khi đó = trung bình các value.
- Confidence : Cao

HAI TIEN

Prediction 3 - Một score lớn hơn rất nhiều, $s = [1, 1, 10]$
- Prediction: attention gần như one-hot vào phần tử thứ 3 (≈ 0.9998), hai phần tử còn lại $\approx 0,0001$
- Reason: $e^9 \approx 8100$ lần; context + recto bằng vậy
- Confidence: Cao

Prediction 4: - Sequence 10 → 1000 token, chi phí attention thay đổi như thế nào?

- Prediction: Tăng khoảng 10000 lần ($100 \to 1000000$ phần tử của attention matrix)
- Reason: mỗi token tính score với mọi token khác → attention matrix $T \times T$ nên chi phí $O(T^2)$ (nhân thêm d cho phép tính QK^T và AV)
- Confidence: Cao (về lý thuyết; thời gian do thực tế có thể tăng ít hơn ở T nhỏ do chạy song song)

Prediction 5: Attention có luôn chọn đúng token con người cho là quan trọng nhất không?

- Prediction: Không
- Reason: weight được học để giảm loss, không bắt ép phải giống hệt cách con người; attention có thể dồn vào dấu câu, từ hay gặp, hoặc phần tần thêm; weight cao ≠ đúng nghĩa token đó → dễ bị prediction (value và các layer sau cũng ảnh hưởng)
- Confidence: Tb - cao